Laporan Tugas Data Mining

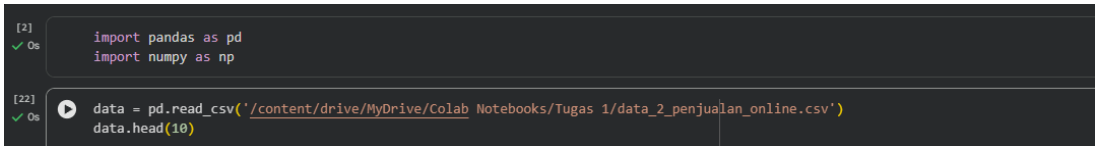
Kasus 2 – Penjualan Toko Online (120 data)

Disusun oleh:

1. Immanuella Audrey Soegito (Mengerjakan Kasus + Data)
2. Salsabiila Dwike Sevtuari (Pembuat Kasus + Data)

PRA-PROSES

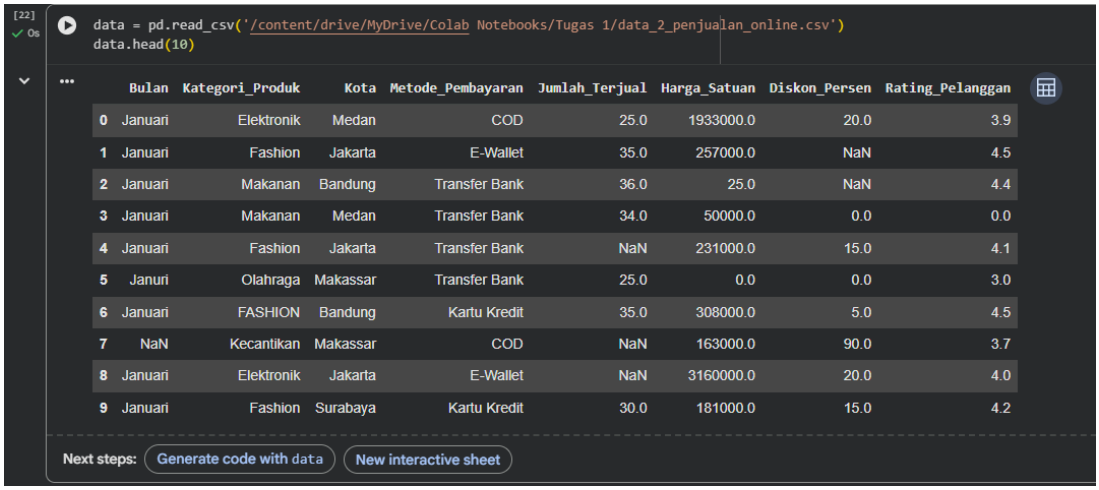
- Input: File data_2_penjualan_online.csv.
- Proses: Memuat dataset menggunakan library pandas (pd.read_csv) untuk melihat gambaran awal data.



```
[2]
✓ 0s
import pandas as pd
import numpy as np

[22]
✓ 0s
data = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/Tugas 1/data_2_penjualan_online.csv')
data.head(10)
```

- Output: Menampilan 10 data teratas (Bulan, Kategori_Produk, Kota, Metode_Pembayaran, Jumlah_Terjual, Harga_Satuan, Diskon_Persen, Rating_Pelanggan).



```
[22]
✓ 0s
data = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/Tugas 1/data_2_penjualan_online.csv')
data.head(10)
```

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	Januari	Elektronik	Medan	COD	25.0	1933000.0	20.0	3.9
1	Januari	Fashion	Jakarta	E-Wallet	35.0	257000.0	NaN	4.5
2	Januari	Makanan	Bandung	Transfer Bank	36.0	25.0	NaN	4.4
3	Januari	Makanan	Medan	Transfer Bank	34.0	50000.0	0.0	0.0
4	Januari	Fashion	Jakarta	Transfer Bank	NaN	231000.0	15.0	4.1
5	Januri	Olahraga	Makassar	Transfer Bank	25.0	0.0	0.0	3.0
6	Januari	FASHION	Bandung	Kartu Kredit	35.0	308000.0	5.0	4.5
7	NaN	Kecantikan	Makassar	COD	NaN	163000.0	90.0	3.7
8	Januari	Elektronik	Jakarta	E-Wallet	NaN	3160000.0	20.0	4.0
9	Januari	Fashion	Surabaya	Kartu Kredit	30.0	181000.0	15.0	4.2

Next steps: Generate code with data | New interactive sheet

BAGIAN 1: DATA CLEANSING

1. Mistake During Data Entry

1.1 Check Writing Variations

- **Input:** Kolom kategorik (Bulan, Kategori_Produk, Kota, Metode_Pembayaran).
- **Proses:** Menggunakan groupby().size() untuk melihat variasi penulisan (typo, spasi ganda, salah kapital).

1. Mistake During Data Entry

1.1 Check Writing Variations

```
[24]
✓ 0s
for col in ['Bulan', 'Kategori_Produk', 'Kota', 'Metode_Pembayaran']:
    print(data.groupby(col).size())
    print()
```

- **Output:** Ditemukan banyak variasi penulisan seperti "Januri", "FASHON", "Medn", dan spasi berlebih.

```
Bulan
  April          1
  Desember       1
  Februari       1
  Mei            1
  September      1
-                1
Agustus         10
Agustus          1
Agutus           1
April            5
Desember        10
Desmber          1
FEBRUARI         1
Februari         8
JULI             1
Januari          8
Januri           1
Jul              1
Juli             7
Juni             8
MEI              1
Mai              1
Maret            8
Maret            1
```

1.2 Standardize Letter Case

- **Input:** Kolom kategorik yang memiliki huruf besar-kecil tidak konsisten.
- **Proses:** Menggunakan .str.upper() untuk menyeragamkan seluruh teks menjadi huruf kapital.

```
[25]
✓ 0s
for col in ['Bulan', 'Kategori_Produk', 'Kota', 'Metode_Pembayaran']:
    data[col] = data[col].str.upper()
data[['Bulan', 'Kategori_Produk', 'Kota', 'Metode_Pembayaran']].head(10)

Show hidden output
```

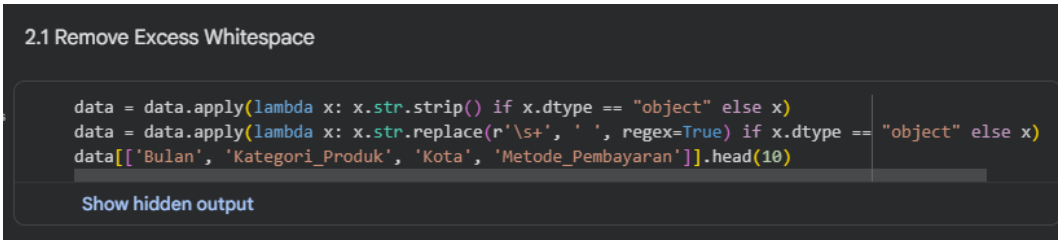
- **Output:** Seluruh label pada kolom kategorik sudah berformat HURUF BESAR.

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran
0	JANUARI	ELEKTRONIK	MEDAN	COD
1	JANUARI	FASHION	JAKARTA	E-WALLET
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK
3	JANUARI	MAKANAN	MEDAN	TRANSFER BANK
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK
5	JANURI	OLAHRAGA	MAKASSAR	TRANSFER BANK
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT
7	NaN	KECANTIKAN	MAKASSAR	COD
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET
9	JANUARI	FASHION	SURABAYA	KARTU KREDIT

2. Redundant Whitespace

2.1 Remove Excess Whitespace

- **Input:** Kolom kategorik yang masih memiliki spasi di awal, akhir, atau spasi ganda di tengah.
- **Proses:** Menggunakan .str.strip() untuk memotong spasi di ujung, dan .str.replace(r'\s+', ' ', regex=True) untuk mengubah spasi ganda menjadi satu spasi.



- **Output:** Seluruh teks bersih dari spasi berlebih (misal "E WALLET" menjadi "E-WALLET").

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran
0	JANUARI	ELEKTRONIK	MEDAN	COD
1	JANUARI	FASHION	JAKARTA	E-WALLET
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK
3	JANUARI	MAKANAN	MEDAN	TRANSFER BANK
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK
5	JANURI	OLAHRAGA	MAKASSAR	TRANSFER BANK
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT
7	NaN	KECANTIKAN	MAKASSAR	COD
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET
9	JANUARI	FASHION	SURABAYA	KARTU KREDIT

2.2 Fix Typos with replace()

- **Input:** Kolom kategorik yang masih memiliki salah ketik (typo) karakter.
- **Proses:** Menggunakan .replace("salah", "benar") secara eksplisit untuk setiap typo yang ditemukan (misal "ELEKTONIK" menjadi "ELEKTRONIK", "JANURI" menjadi "JANUARI").

2.2 Fix Typos

```
data["Kategori_Produk"] = data["Kategori_Produk"].replace("ELEKTONIK", "ELEKTRONIK")
data["Kategori_Produk"] = data["Kategori_Produk"].replace("FASHON", "FASHION")
data["Kategori_Produk"] = data["Kategori_Produk"].replace("MAKANNAN", "MAKANAN")
data["Kategori_Produk"] = data["Kategori_Produk"].replace("KECANTIKN", "KECANTIKAN")
data["Kategori_Produk"] = data["Kategori_Produk"].replace("OLAH RAGA", "OLAHRAGA")

data["Kota"] = data["Kota"].replace("SURABYA", "SURABAYA")
data["Kota"] = data["Kota"].replace("JAKRTA", "JAKARTA")
data["Kota"] = data["Kota"].replace("BANDUG", "BANDUNG")
data["Kota"] = data["Kota"].replace("MEDN", "MEDAN")
data["Kota"] = data["Kota"].replace("MAKASAR", "MAKASSAR")

data["Metode_Pembayaran"] = data["Metode_Pembayaran"].replace("TRANSFER BNK", "TRANSFER BANK")
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].replace("E WALLET", "E-WALLET")
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].replace("EWALLET", "E-WALLET")
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].replace("COD.", "COD")
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].replace("KARTU KREDITT", "KARTU KREDIT")

data["Bulan"] = data["Bulan"].replace("JANURI", "JANUARI")
data["Bulan"] = data["Bulan"].replace("FEBUARI", "FEBRUARI")
data["Bulan"] = data["Bulan"].replace("MART", "MARET")
data["Bulan"] = data["Bulan"].replace("APRILL", "APRIL")
data["Bulan"] = data["Bulan"].replace("MAI", "MEI")
data["Bulan"] = data["Bulan"].replace("JUN", "JUNI")
data["Bulan"] = data["Bulan"].replace("JUL", "JULI")
data["Bulan"] = data["Bulan"].replace("AGUTUS", "AGUSTUS")
data["Bulan"] = data["Bulan"].replace("SEPETMBER", "SEPTEMBER")
data["Bulan"] = data["Bulan"].replace("OKOTBER", "OKTOBER")
data["Bulan"] = data["Bulan"].replace("NOPEMBER", "NOVEMBER")
data["Bulan"] = data["Bulan"].replace("DESMBER", "DESEMBER")

for col in ['Bulan', 'Kategori_Produk', 'Kota', 'Metode_Pembayaran']:
    print(data.groupby(col).size())
    print()
```

- **Output:** Data kategorik menjadi seragam. Jumlah kategori tervalidasi (misal Bulan menjadi 12, Kategori_Produk menjadi 5).

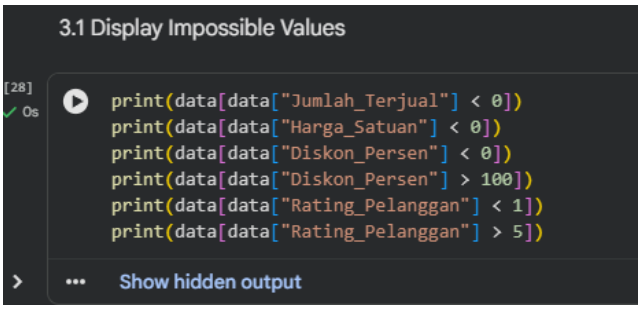
```
    Bulan
...  -            1
     AGUSTUS     12
     APRIL        6
     DESEMBER    12
     FEBRUARI    11
     JANUARI      9
     JULI         9
     JUNI         9
     MARET       10
     MEI         12
     NOVEMBER     6
     OKTOBER      6
     SEPTEMBER   11
     UNKNOWN      1
     dtype: int64

     Kategori_Produk
```

3. Impossible Value

3.1 Display Impossible Values

- **Input:** Kolom numerik (Jumlah_Terjual, Harga_Satuan, Diskon_Persen, Rating_Pelanggan).
- **Proses:** Melakukan *filtering* untuk menampilkan data yang tidak masuk akal (misal Harga minus, Diskon > 100%, Rating < 1 atau > 5).



- **Output:** Ditemukan baris dengan Jumlah_Terjual negatif, Harga_Satuan negatif, Diskon 150%, dan Rating 0 atau 7.5.

```
...     Bulan Kategori_Produk      Kota Metode_Pembayaran  Jumlah_Terjual  \
    48   MEI      KECANTIKAN  SURABAYA              COD            -8.0
    49   MEI      ELEKTRONIK     MEDAN              COD           -15.0

        Harga_Satuan  Diskon_Persen  Rating_Pelanggan
    48      222000.0            NaN               4.3
    49     3338000.0            5.0               4.0
       Bulan Kategori_Produk     Kota Metode_Pembayaran  Jumlah_Terjual  \
    81  AGUSTUS            NaN  BANDUNG               COD            36.0

        Harga_Satuan  Diskon_Persen  Rating_Pelanggan
    81     -250000.0            5.0               3.9
    Bulan Kategori_Produk Kota Metode_Pembayaran  Jumlah_Terjual  Harga_Satuan  \
    63  JULI        OLAHRAGA  NaN          E-WALLET            32.0      286000.0

        Diskon_Persen  Rating_Pelanggan
    63          -10.0               3.7
          Bulan Kategori_Produk      Kota Metode_Pembayaran  Jumlah_Terjual  \
    91   SEPTEMBER      ELEKTRONIK   JAKARTA      KARTU KREDIT           350.0
    111   DESEMBER         FASHION  MAKASSAR      KARTU KREDIT            32.0

         Harga_Satuan  Diskon_Persen  Rating_Pelanggan
    91      2063000.0          120.0               4.1
    111      184000.0          150.0               4.1
           Bulan Kategori_Produk     Kota Metode_Pembayaran  Jumlah_Terjual  \
    3     JANUARI         MAKANAN    MEDAN     TRANSFER BANK            34.0
    12   FEBRUARI         FASHION    MEDAN     TRANSFER BANK            43.0
    85  SEPTEMBER      ELEKTRONIK  JAKARTA               COD            33.0

        Harga_Satuan  Diskon_Persen  Rating_Pelanggan
    3        50000.0            0.0               0.0
    12      356000.0           20.0              -1.0
    85     3999000.0           15.0               0.0
          Bulan Kategori_Produk      Kota Metode_Pembayaran  Jumlah_Terjual  \
    13  FEBRUARI         MAKANAN     MEDAN          E-WALLET             NaN
    70   AGUSTUS         FASHION  SURABAYA      KARTU KREDIT            24.0
```

3.2 Solution 2: Drop Rows

- **Input:** Baris-baris yang teridentifikasi memiliki *impossible value*.
- **Proses:** Menghapus baris tersebut menggunakan data.drop().

```
[29]
✓ 0s
    print('Jumlah baris sebelum:', data.shape[0])

    data = data.drop(data[(data["Jumlah_Terjual"] < 0)].index)
    data = data.drop(data[(data["Harga_Satuan"] < 0)].index)
    data = data.drop(data[(data["Diskon_Persen"] < 0) | (data["Diskon_Persen"] > 100)].index)
    data = data.drop(data[(data["Rating_Pelanggan"] < 1) | (data["Rating_Pelanggan"] > 5)].index)

    print('Jumlah baris sesudah:', data.shape[0])
    data.head(10)

    Show hidden output
```

- **Output:** Jumlah baris berkurang dari 120 baris menjadi 109 baris. Data numerik sekarang berada di rentang yang logis.

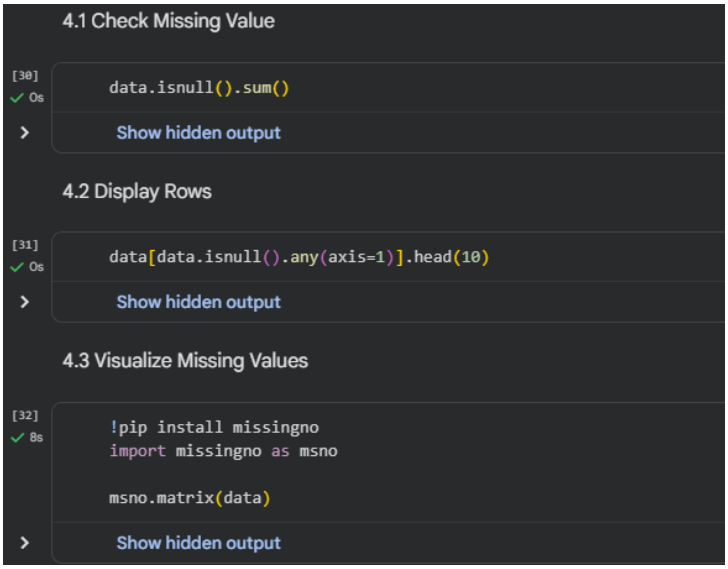
```
Jumlah baris sebelum: 120
Jumlah baris sesudah: 109
```

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	25.0	1933000.0	20.0	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	35.0	257000.0	NaN	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	36.0	25.0	NaN	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	NaN	231000.0	15.0	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	25.0	0.0	0.0	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	35.0	308000.0	5.0	4.5
7	NaN	KECANTIKAN	MAKASSAR	COD	NaN	163000.0	90.0	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	NaN	3160000.0	20.0	4.0
9	JANUARI	FASHION	SURABAYA	KARTU KREDIT	30.0	181000.0	15.0	4.2
10	FEBRUARI	FASHION	SURABAYA	TRANSFER BANK	25.0	194000.0	10.0	4.3

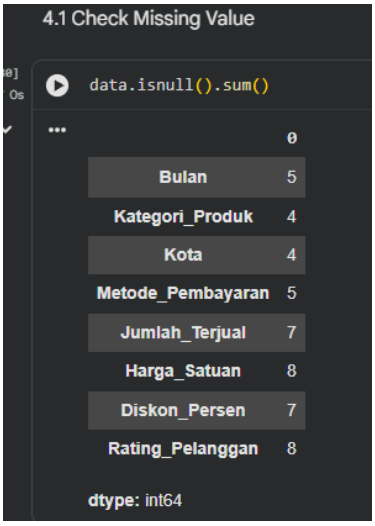
4. Missing Value

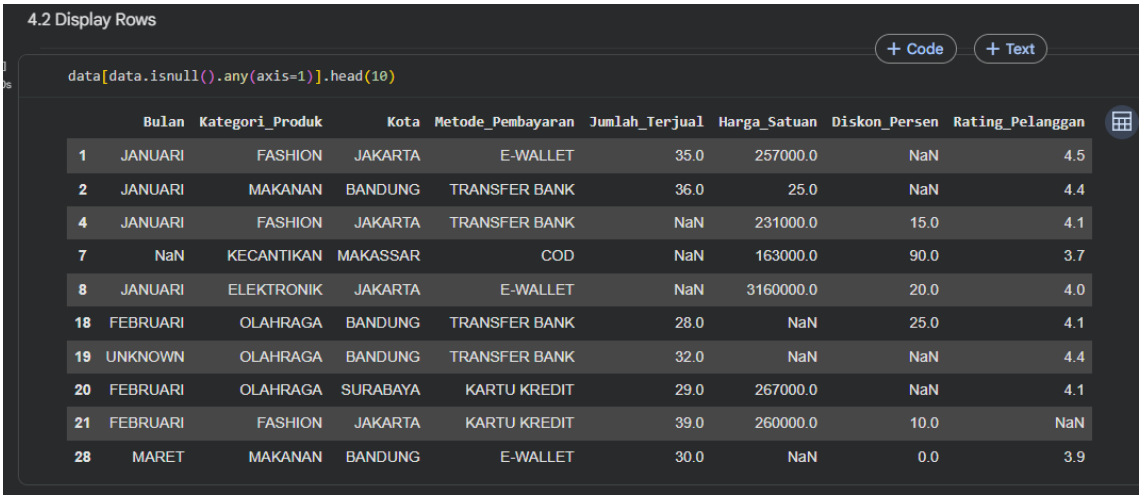
4.1 - 4.3 Check & Visualize Missing Values

- **Input:** Dataset yang sudah dibersihkan dari *impossible value*.
- **Proses:** Mengecek jumlah nilai kosong dengan isnull().sum() dan memvisualisasikannya dengan library missingno.

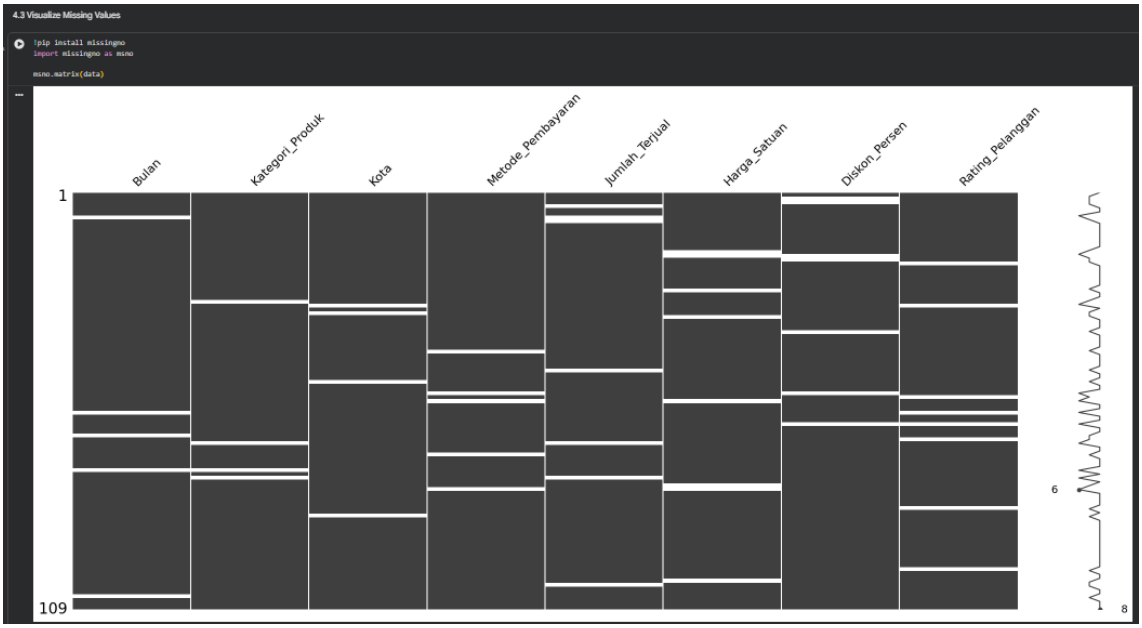


- **Output:** Ditemukan nilai kosong pada hampir seluruh kolom (Bulan: 5, Kategori: 5, Kota: 4, Metode: 5, Jumlah: 7, Harga: 8, Diskon: 6, Rating: 8).



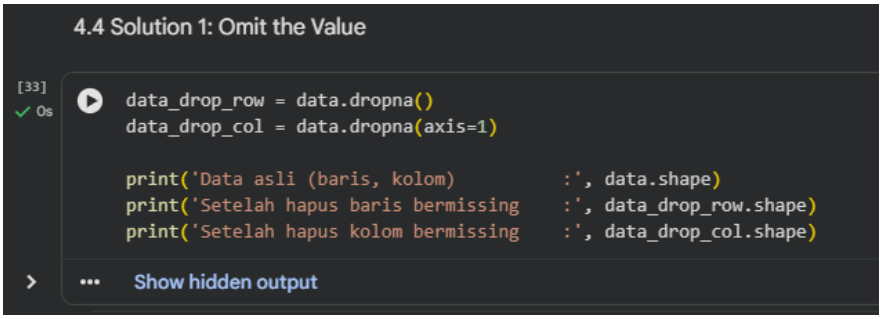


	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
1	JANUARI	FASHION	JAKARTA	E-WALLET	35.0	257000.0	NaN	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	36.0	25.0	NaN	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	NaN	231000.0	15.0	4.1
7	NaN	KECANTIKAN	MAKASSAR	COD	NaN	163000.0	90.0	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	NaN	3160000.0	20.0	4.0
18	FEBRUARI	OLAHRAGA	BANDUNG	TRANSFER BANK	28.0	NaN	25.0	4.1
19	UNKNOWN	OLAHRAGA	BANDUNG	TRANSFER BANK	32.0	NaN	NaN	4.4
20	FEBRUARI	OLAHRAGA	SURABAYA	KARTU KREDIT	29.0	267000.0	NaN	4.1
21	FEBRUARI	FASHION	JAKARTA	KARTU KREDIT	39.0	260000.0	10.0	NaN
28	MARET	MAKANAN	BANDUNG	E-WALLET	30.0	NaN	0.0	3.9

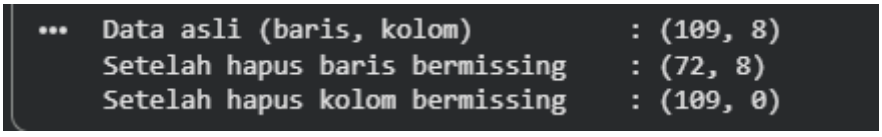


4.4 Solution 1: Omit the Value (Pembanding)

- **Input:** Dataset dengan nilai kosong.
- **Proses:** Menggunakan dropna().



- **Output:** Jika baris dihapus, sisa data hanya 72 baris (banyak data hilang). Jika kolom dihapus, sisa 0 kolom. *Kesimpulan: metode ini tidak dipakai karena merusak data*.



4.5 Solution 2: Set Value to NULL

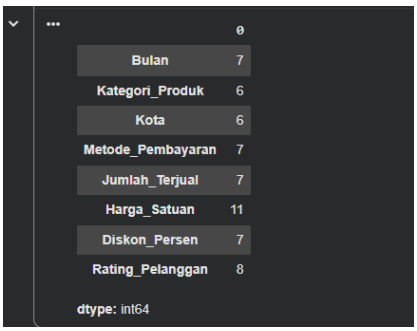
- **Input:** Dataset yang memiliki nilai penanda kosong seperti "-", "UNKNOWN", dan angka 0 pada Harga.
- **Proses:** Mengganti nilai penanda tersebut dengan np.nan (standar nilai kosong di pandas).

4.5 Solution 2: Set Value to NULL

```
data_null = data.replace(["-", "UNKNOWN"], np.nan)
data_null[['Harga_Satuan']] = data_null[['Harga_Satuan']].replace(0, np.nan)
data = data_null
data.isnull().sum()
```

Show hidden output

- **Output:** Nilai kosong terdeteksi secara akurat (Harga_Satuan bertambah menjadi 11 data kosong).



	0
Bulan	7
Kategori_Produk	6
Kota	6
Metode_Pembayaran	7
Jumlah_Terjual	7
Harga_Satuan	11
Diskon_Persen	7
Rating_Pelanggan	8

dtype: int64

4.6 & 4.7 Statistik Deskriptif (Sesuai Syarat Minimum)

- **Input:** Dataset dengan nilai NaN.
- **Proses:** Menjalankan describe() untuk melihat mean, median, dan modus (top).

4.6 Descriptive Statistics Before Imputation

[35] 0s

```
print(data[['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']].describe())
print()
print(data[['Bulan', 'Kategori_Produk', 'Kota', 'Metode_Pembayaran']].describe())
```

Show hidden output

- **Output:**
  - Rata-rata (mean) Jumlah_Terjual: 37.706
  - Rata-rata (mean) Harga_Satuan: 1330224.490
  - Rata-rata (mean) Diskon_Persen: 14.029
  - Modus (top) Kota: JAKARTA
  - Modus (top) Metode_Pembayaran: E-WALLET

```
       Jumlah_Terjual  Harga_Satuan  Diskon_Persen  Rating_Pelanggan
count      102.000000  9.800000e+01     102.000000        101.000000
mean        37.911765  1.254951e+06      14.264706          4.080198
std         51.850910  4.568711e+06      13.394196          0.442949
min         20.000000  2.300000e+01       0.000000          3.000000
25%         26.250000  4.000000e+04       5.000000          3.800000
50%         30.000000  2.040000e+05      15.000000          4.100000
75%         34.750000  4.435000e+05      20.000000          4.400000
max        420.000000  3.500000e+07      90.000000          5.000000

             Bulan Kategori_Produk     Kota Metode_Pembayaran
count          102             103      103               102
unique          12               5        5                 4
top     DESEMBER         MAKANAN  JAKARTA         E-WALLET
freq            11              33       24                35
```

4.8 Solution 3: Impute with the Mean and Mode

- **Input:** Dataset dengan nilai NaN dan hasil statistik deskriptif.
- **Proses:** Mengisi nilai numerik yang kosong menggunakan nilai rata-rata (mean()), dan mengisi nilai kategorik yang kosong menggunakan nilai yang paling sering muncul (mode()[0])

```
data_fill0 = data.fillna(0)
data_fill0.head(10)
```

Show hidden output

Next steps: Generate code with data_fill0 | New interactive sheet

4.8 Solution 3: Impute with the Mean and Mode

```
data["Jumlah_Terjual"]   = data["Jumlah_Terjual"].fillna(data["Jumlah_Terjual"].mean())
data["Harga_Satuan"]     = data["Harga_Satuan"].fillna(data["Harga_Satuan"].mean())
data["Diskon_Persen"]    = data["Diskon_Persen"].fillna(data["Diskon_Persen"].mean())
data["Rating_Pelanggan"] = data["Rating_Pelanggan"].fillna(data["Rating_Pelanggan"].mean())

data["Bulan"]            = data["Bulan"].fillna(data["Bulan"].mode()[0])
data["Kategori_Produk"]  = data["Kategori_Produk"].fillna(data["Kategori_Produk"].mode()[0])
data["Kota"]             = data["Kota"].fillna(data["Kota"].mode()[0])
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].fillna(data["Metode_Pembayaran"].mode()[0])

data.isnull().sum()
```

Show hidden output

- **Output:** Seluruh missing value telah terisi. Jumlah data (count) kembali penuh menjadi 109 baris untuk semua kolom.

4.7 Solution 3: Impute a Static Value to 0

```
data_fill0 = data.fillna(0)
data_fill0.head(10)
```

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	25.0	1933000.0	20.0	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	35.0	257000.0	0.0	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	36.0	25.0	0.0	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	0.0	231000.0	15.0	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	25.0	0.0	0.0	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	35.0	308000.0	5.0	4.5
7	0	KECANTIKAN	MAKASSAR	COD	0.0	163000.0	90.0	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	0.0	3160000.0	20.0	4.0
9	JANUARI	FASHION	SURABAYA	KARTU KREDIT	30.0	181000.0	15.0	4.2
10	FEBRUARI	FASHION	SURABAYA	TRANSFER BANK	25.0	194000.0	10.0	4.3

Next steps: Generate code with data_fill0 | New interactive sheet

4.8 Solution 3: Impute with the Mean and Mode

```
data["Jumlah_Terjual"]   = data["Jumlah_Terjual"].fillna(data["Jumlah_Terjual"].mean())
data["Harga_Satuan"]     = data["Harga_Satuan"].fillna(data["Harga_Satuan"].mean())
data["Diskon_Persen"]    = data["Diskon_Persen"].fillna(data["Diskon_Persen"].mean())
data["Rating_Pelanggan"] = data["Rating_Pelanggan"].fillna(data["Rating_Pelanggan"].mean())

data["Bulan"]            = data["Bulan"].fillna(data["Bulan"].mode()[0])
data["Kategori_Produk"]  = data["Kategori_Produk"].fillna(data["Kategori_Produk"].mode()[0])
data["Kota"]             = data["Kota"].fillna(data["Kota"].mode()[0])
data["Metode_Pembayaran"] = data["Metode_Pembayaran"].fillna(data["Metode_Pembayaran"].mode()[0])

data.isnull().sum()
```

	0
Bulan	0
Kategori_Produk	0
Kota	0
Metode_Pembayaran	0
Jumlah_Terjual	0
Harga_Satuan	0
Diskon_Persen	0
Rating_Pelanggan	0

dtype: int64

4.9 Descriptive Statistics After Imputation

```
data[['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']].describe()
```

	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
count	109.000000	1.090000e+02	109.000000	109.000000
mean	37.911765	1.254951e+06	14.264706	4.080198
std	50.142409	4.329798e+06	12.952854	0.426228
min	20.000000	2.300000e+01	0.000000	3.000000
25%	27.000000	4.000000e+04	5.000000	3.800000
50%	31.000000	2.400000e+05	14.264706	4.080198
75%	35.000000	1.254951e+06	20.000000	4.400000
max	420.000000	3.500000e+07	90.000000	5.000000

5. Outlier

5.1 & 5.2 Detect Outliers

- **Input:** Kolom numerik pada dataset yang sudah bersih dari *missing value*.

- **Proses:** Menggunakan visualisasi plt.hist() (Histogram) dan plt.boxplot() (Boxplot) serta mengecek kembali describe().

5.1 Detecting Outliers

```
import matplotlib.pyplot as plt

for col in ['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']:
    plt.hist(data[col], edgecolor='black', linewidth=0.2)
    plt.xlabel(col)
    plt.ylabel('Frequency')
    plt.show()

    plt.boxplot(data[col])
    plt.show()
```

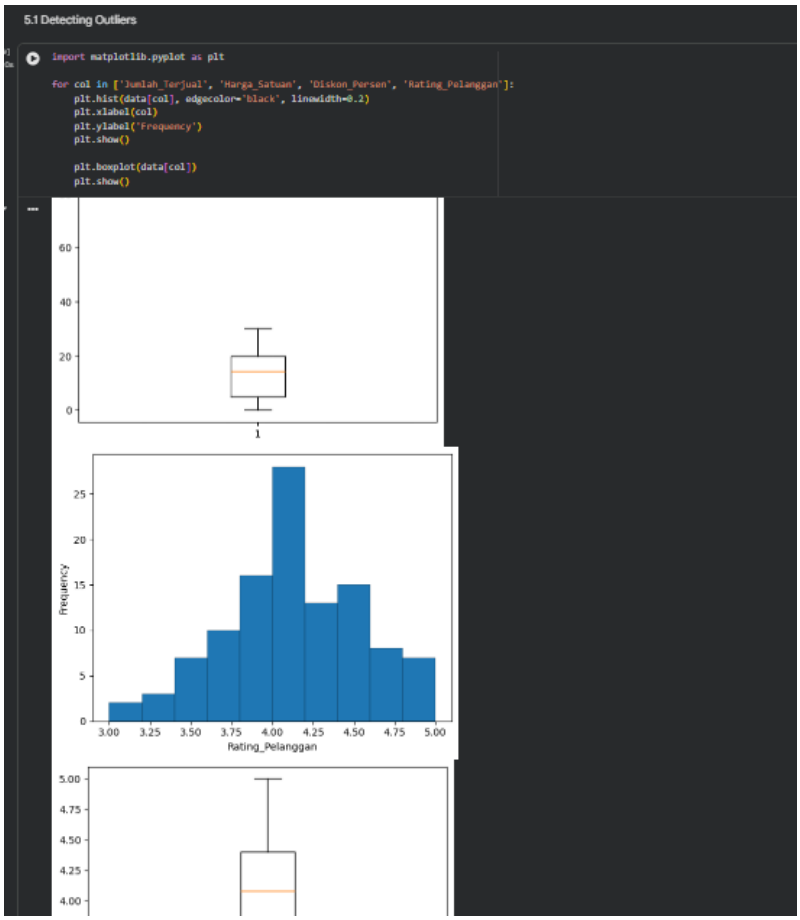
Show hidden output

5.2 Reading the Plots

```
data[['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']].describe()
```

Show hidden output

- **Output:** Terlihat pada boxplot terdapat pencilan (outlier) ekstrem, terutama pada Harga_Satuan (nilai max mencapai 35.000.000) dan Jumlah_Terjual (max 420 unit).



```
data[['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']].describe()
```

	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
count	109.000000	1.090000e+02	109.000000	109.000000
mean	37.911765	1.254951e+06	14.264706	4.080198
std	50.142409	4.329798e+06	12.952854	0.426228
min	20.000000	2.300000e+01	0.000000	3.000000
25%	27.000000	4.000000e+04	5.000000	3.800000
50%	31.000000	2.400000e+05	14.264706	4.080198
75%	35.000000	1.254951e+06	20.000000	4.400000
max	420.000000	3.500000e+07	90.000000	5.000000

BAGIAN 2: DATA TRANSFORMATION

Dataset yang digunakan adalah hasil dari Data Cleansing (data_clean).

2. DATA TRANSFORMATION

1. Transformation Input Data

1.1 Copy Clean Data

```
data_clean = data.copy()
data_clean.head(8)
```

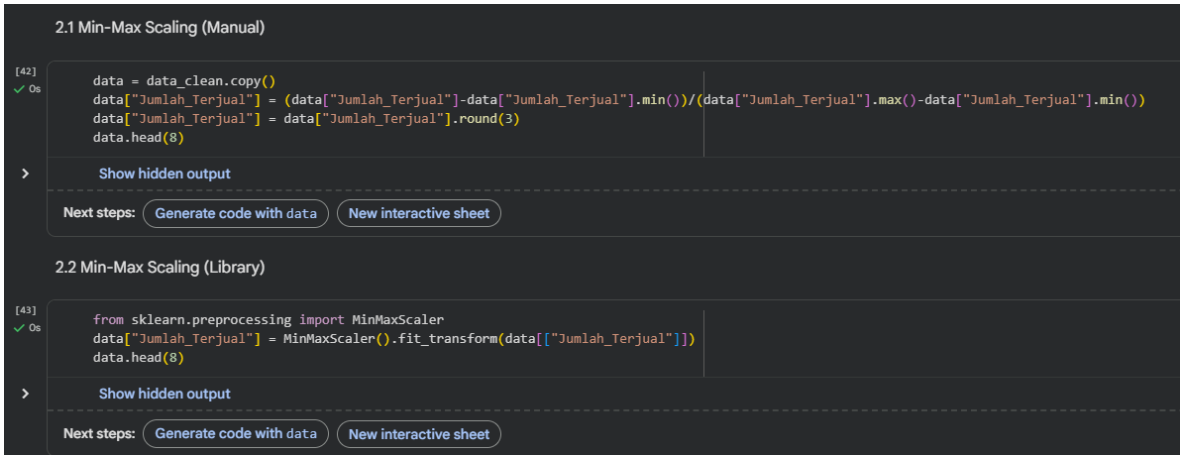
	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	25.000000	1.933000e+06	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	35.000000	2.570000e+05	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	36.000000	2.500000e+01	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	37.911765	2.310000e+05	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	25.000000	1.254951e+06	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	35.000000	3.080000e+05	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	37.911765	1.630000e+05	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	37.911765	3.160000e+06	20.000000	4.0

Next steps: Generate code with data_clean | New interactive sheet

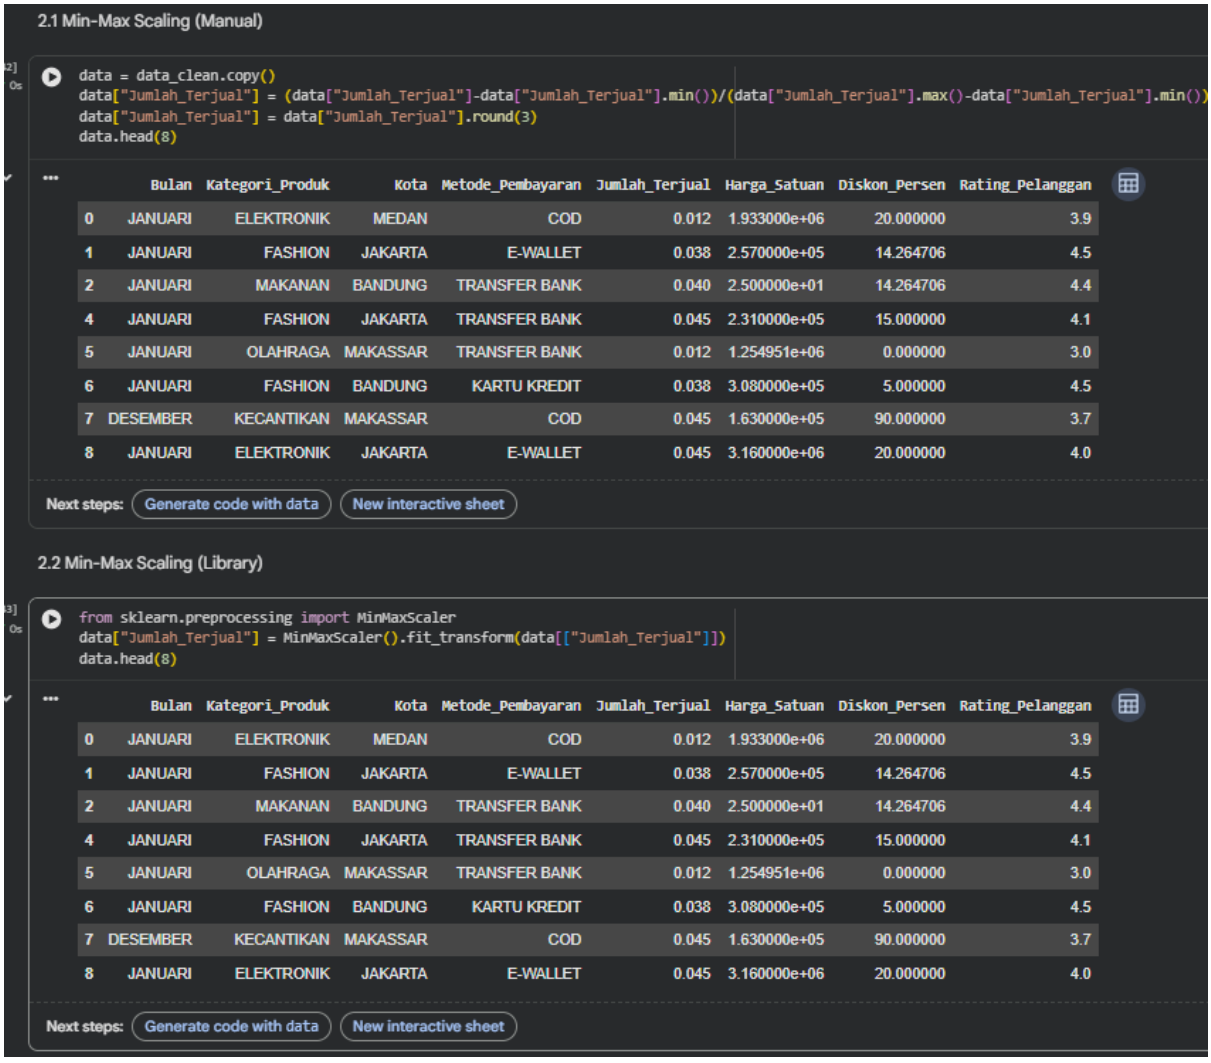
1. Scaling (Contoh pada kolom Jumlah_Terjual)

1.1 & 1.2 Min-Max Scaling (Manual & Library)

- **Input:** Kolom Jumlah_Terjual.
- **Proses:** Manual: $(x - min)/(max - min)$. Library: MinMaxScaler().fit_transform.

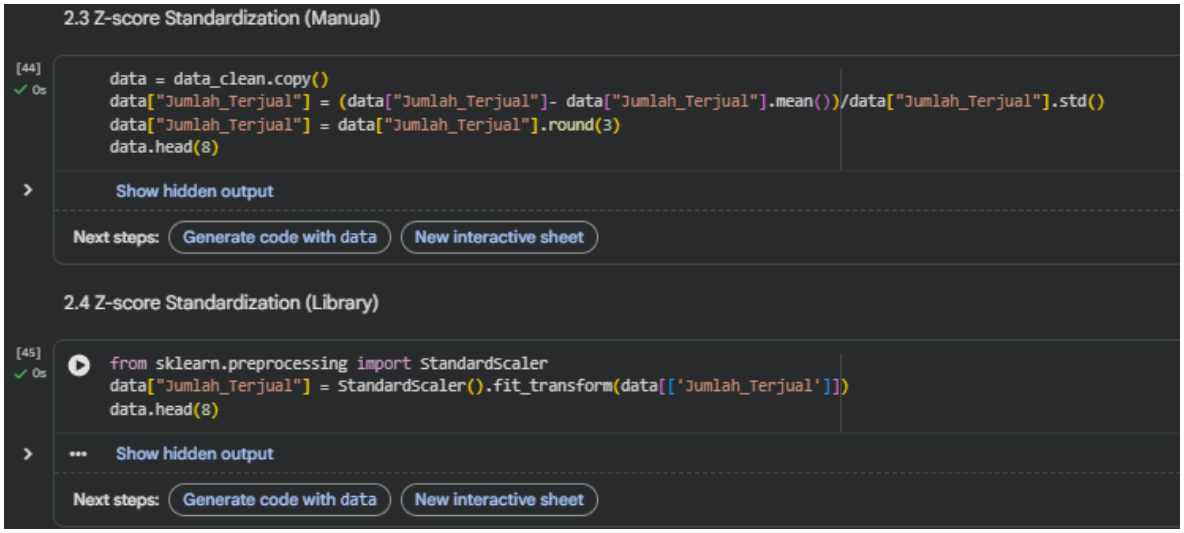


- **Output:** Nilai data berubah menjadi rentang 0.000 hingga 1.000.

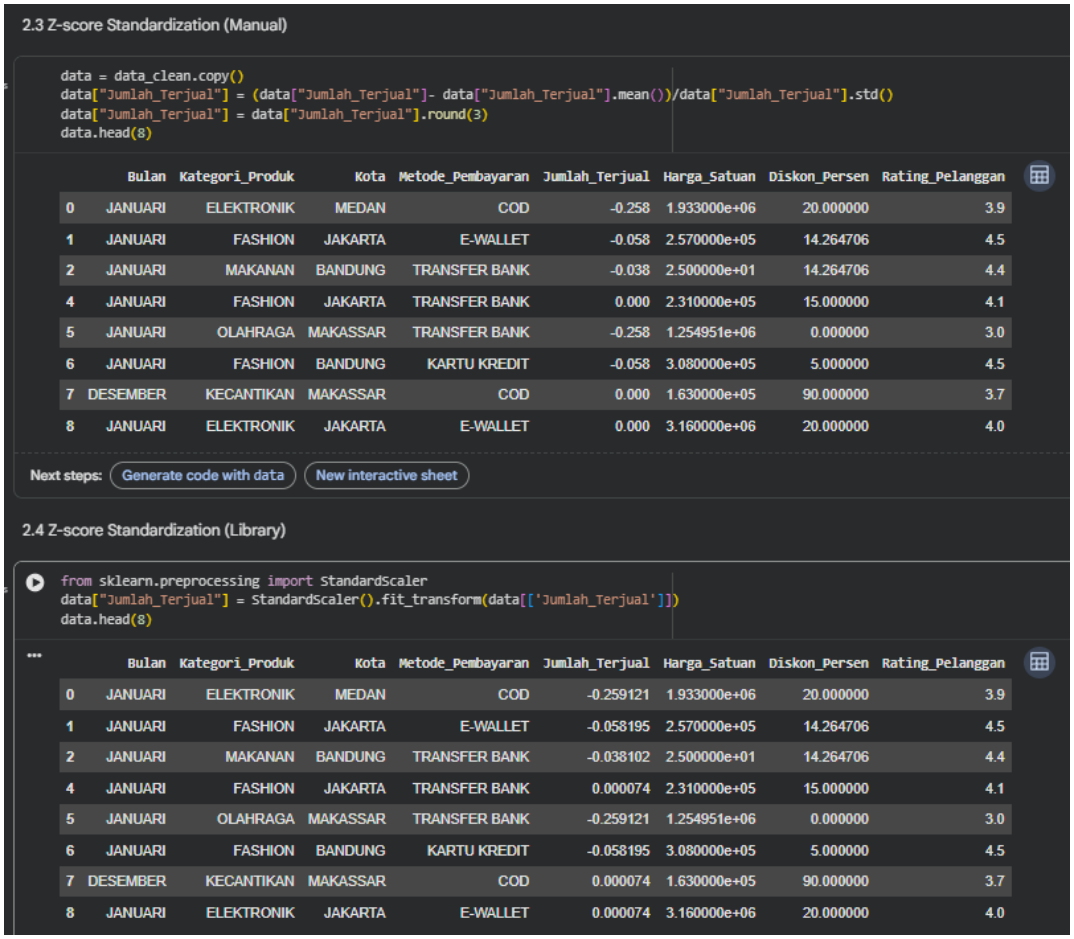


1.3 & 1.4 Z-score Standardization (Manual & Library)

- **Input:** Kolom Jumlah_Terjual.
- **Proses:** Manual: $(x - mean)/std$. Library: StandardScaler().fit_transform.



- **Output:** Data berpusat pada 0 dengan standar deviasi 1 (contoh nilai: -0.254).

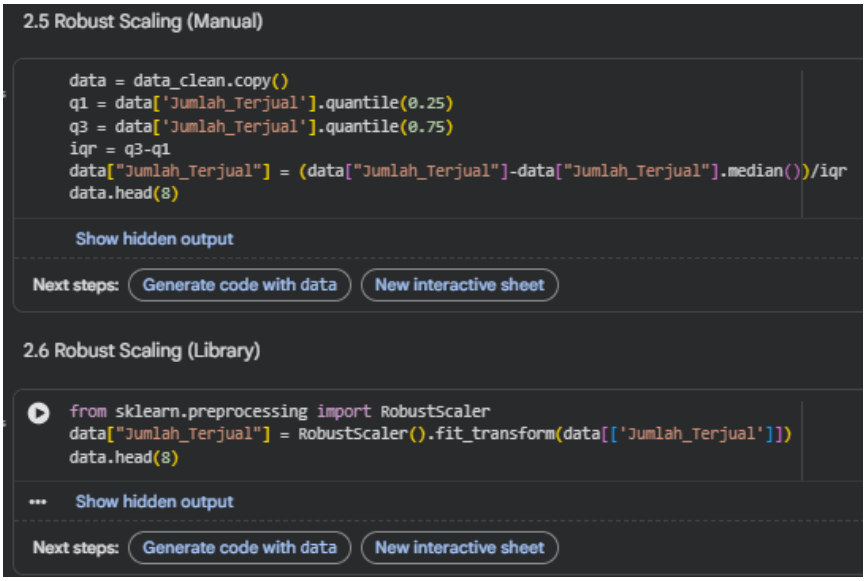


	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	-0.258	1.933000e+06	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	-0.058	2.570000e+05	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	-0.038	2.500000e+01	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	0.000	2.310000e+05	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	-0.258	1.254951e+06	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	-0.058	3.080000e+05	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	0.000	1.630000e+05	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	0.000	3.160000e+06	20.000000	4.0

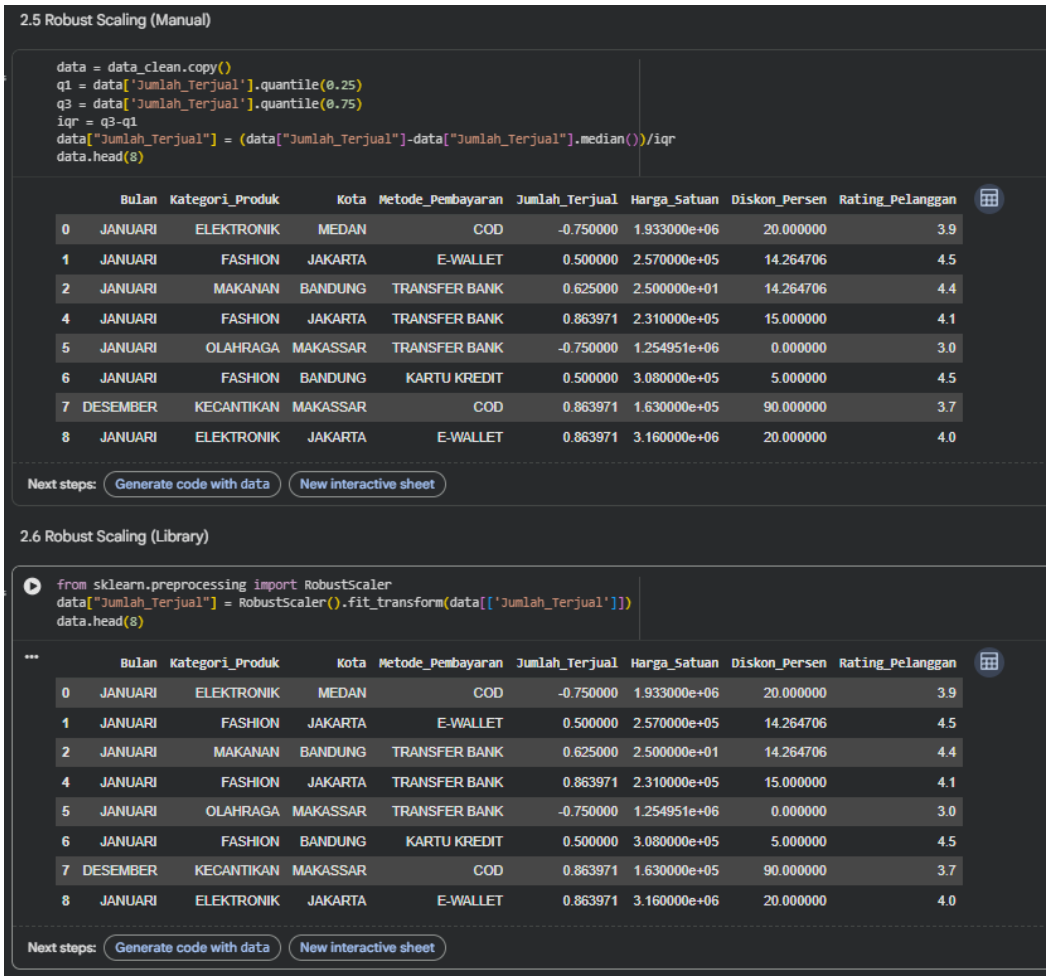
	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	-0.259121	1.933000e+06	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	-0.058195	2.570000e+05	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	-0.038102	2.500000e+01	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	0.000074	2.310000e+05	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	-0.259121	1.254951e+06	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	-0.058195	3.080000e+05	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	0.000074	1.630000e+05	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	0.000074	3.160000e+06	20.000000	4.0

1.5 & 1.6 Robust Scaling (Manual & Library)

- **Input:** Kolom Jumlah_Terjual.
- **Proses:** Manual: $(x - median)/IQR$. Library: RobustScaler().fit_transform.



- **Output:** Data diskalakan menggunakan kuartil, lebih tahan terhadap *outlier*.



	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	-0.750000	1.933000e+06	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	0.500000	2.570000e+05	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	0.625000	2.500000e+01	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	0.863971	2.310000e+05	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	-0.750000	1.254951e+06	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	0.500000	3.080000e+05	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	0.863971	1.630000e+05	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	0.863971	3.160000e+06	20.000000	4.0

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	-0.750000	1.933000e+06	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	0.500000	2.570000e+05	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	0.625000	2.500000e+01	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	0.863971	2.310000e+05	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	-0.750000	1.254951e+06	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	0.500000	3.080000e+05	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	0.863971	1.630000e+05	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	0.863971	3.160000e+06	20.000000	4.0

2. Encoding

2.1 Label Encoding

- **Input:** Kolom kategorik Kategori_Produk.

- **Proses:** LabelEncoder().fit_transform.

3.1 Label Encoding

```
from sklearn.preprocessing import LabelEncoder
data = data_clean.copy()
label_encoder = LabelEncoder()
data['Kategori_Produk_encoded'] = label_encoder.fit_transform(data['Kategori_Produk'])
print(list(label_encoder.classes_), '-> kode 0 sampai', len(label_encoder.classes_)-1)
data[['Kategori_Produk', 'Kategori_Produk_encoded']].head(8)
```

- **Output:** Teks diubah menjadi angka (Contoh: ELEKTRONIK = 0, FASHION = 1, KECANTIKAN = 2, dst).

```
['ELEKTRONIK', 'FASHION', 'KECANTIKAN', 'MAKANAN', 'OLAHRAGA'] -> kode 0 sampai 4
```

	Kategori_Produk	Kategori_Produk_encoded
0	ELEKTRONIK	0
1	FASHION	1
2	MAKANAN	3
4	FASHION	1
5	OLAHRAGA	4
6	FASHION	1
7	KECANTIKAN	2
8	ELEKTRONIK	0

3. Data Discretization

3.1 Equal-Width dan Equal-Frequency

- **Input:** Kolom numerik kontinu Harga_Satuan.
- **Proses:** pd.cut(bins=3) untuk membagi rata rentang nilai, dan pd.qcut(q=3) untuk membagi rata jumlah data.

4.1 Equal-Width and Equal-Frequency

```
data = data_clean.copy()
data['Harga_Satuan_Bin'] = pd.cut(data['Harga_Satuan'], bins=3, labels=['Low', 'Medium', 'High'])
data['Harga_Satuan_Quantile'] = pd.qcut(data['Harga_Satuan'], q=3, labels=['Low', 'Medium', 'High'])

print(data['Harga_Satuan_Bin'].value_counts())
print()
print(data['Harga_Satuan_Quantile'].value_counts())
print()
data[['Harga_Satuan', 'Harga_Satuan_Bin', 'Harga_Satuan_Quantile']].head(10)
```

Show hidden output

- **Output:** Terbentuk kolom baru Harga_Satuan_Bin dan Harga_Satuan_Quantile dengan kategori **Low, Medium, High**.

```
Harga_Satuan_Bin
Low       107
High        2
Medium      0
Name: count, dtype: int64

Harga_Satuan_Quantile
High      37
Low       36
Medium    36
Name: count, dtype: int64
```

	Harga_Satuan	Harga_Satuan_Bin	Harga_Satuan_Quantile
0	1.933000e+06	Low	High
1	2.570000e+05	Low	Medium
2	2.500000e+01	Low	Low
4	2.310000e+05	Low	Medium
5	1.254951e+06	Low	High
6	3.080000e+05	Low	Medium
7	1.630000e+05	Low	Medium
8	3.160000e+06	Low	High
9	1.810000e+05	Low	Medium
10	1.940000e+05	Low	Medium

4. Data Measurement and Aggregation

4.1 Different Unit of Measurement

- **Input:** Kolom Harga_Satuan (dalam Rupiah).
- **Proses:** Membagi nilai dengan 10^3.

5.1 Different Unit of Measurement

```
data = data_clean.copy()
data['Harga_Satuan'] = data['Harga_Satuan'] / 10**3
data.head(8)
```

Show hidden output

Next steps: Generate code with data | New interactive sheet

- **Output:** Nilai harga berubah skalanya menjadi ribuan Rupiah (contoh: 1.933.000 menjadi 1.933).

	Bulan	Kategori_Produk	Kota	Metode_Pembayaran	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
0	JANUARI	ELEKTRONIK	MEDAN	COD	25.000000	1933.000000	20.000000	3.9
1	JANUARI	FASHION	JAKARTA	E-WALLET	35.000000	257.000000	14.264706	4.5
2	JANUARI	MAKANAN	BANDUNG	TRANSFER BANK	36.000000	0.025000	14.264706	4.4
4	JANUARI	FASHION	JAKARTA	TRANSFER BANK	37.911765	231.000000	15.000000	4.1
5	JANUARI	OLAHRAGA	MAKASSAR	TRANSFER BANK	25.000000	1254.950888	0.000000	3.0
6	JANUARI	FASHION	BANDUNG	KARTU KREDIT	35.000000	308.000000	5.000000	4.5
7	DESEMBER	KECANTIKAN	MAKASSAR	COD	37.911765	163.000000	90.000000	3.7
8	JANUARI	ELEKTRONIK	JAKARTA	E-WALLET	37.911765	3160.000000	20.000000	4.0

Next steps: Generate code with data | New interactive sheet

4.2 Different Level of Aggregation

- **Input:** Data per transaksi.

- **Proses:** groupby('Bulan').mean().

5.2 Different Level of Aggregation

```
data_num = data[['Bulan', 'Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan']]
data_agg = data_num.groupby('Bulan').mean()
data_agg
```

Show hidden output

Next steps: Generate code with data_agg | New interactive sheet

- **Output:** Data diringkas menjadi rata-rata transaksi per bulan (12 baris data).

Bulan	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan
AGUSTUS	69.782353	2970.851200	21.500000	4.158020
APRIL	28.166667	6413.825148	15.833333	4.063366
DESEMBER	30.879085	469.300488	15.236928	4.092244
FEBRUARI	30.444444	345.002876	16.584967	3.864466
JANUARI	32.727941	915.621986	12.941176	4.075000
JULI	35.125000	1597.368861	10.533088	4.135025
JUNI	29.101307	717.438988	11.029412	4.164466
MARET	31.400000	224.997389	16.000000	3.790000
MEI	30.600000	607.300000	14.426471	4.120000
NOVEMBER	91.833333	939.332648	15.000000	4.500000
OKTOBER	30.166667	566.833333	15.833333	4.100000
SEPTEMBER	31.000000	1458.322420	5.000000	4.053355

4.3 Attribute Construction

- **Input:** Kolom Jumlah_Terjual, Harga_Satuan, dan Diskon_Persen.
- **Proses:** Membuat kolom baru Pendapatan dengan rumus: Jumlah * Harga * (1 - Diskon/100).

5.3 Attribute Construction

```
data['Pendapatan'] = data['Jumlah_Terjual'] * data['Harga_Satuan'] * (1 - data['Diskon_Persen'] / 100)   # dalam ribu rupiah
data[['Jumlah_Terjual', 'Harga_Satuan', 'Diskon_Persen', 'Rating_Pelanggan', 'Pendapatan']].head(8)
```

Show hidden output

- **Output:** Terbentuk kolom Pendapatan yang merepresentasikan total omzet bersih.

	Jumlah_Terjual	Harga_Satuan	Diskon_Persen	Rating_Pelanggan	Pendapatan
0	25.000000	1933.000000	20.000000	3.9	38660.000000
1	35.000000	257.000000	14.264706	4.5	7711.889706
2	36.000000	0.025000	14.264706	4.4	0.771618
4	37.911765	231.000000	15.000000	4.1	7443.975000
5	25.000000	1254.950888	0.000000	3.0	31373.772194
6	35.000000	308.000000	5.000000	4.5	10241.000000
7	37.911765	163.000000	90.000000	3.7	617.961765
8	37.911765	3160.000000	20.000000	4.0	95840.941176

4.4 Data Smoothing

- **Input:** Kolom Jumlah_Terjual dan Harga_Satuan.
- **Proses:** Moving Average (window 3) dan Exponential Smoothing (alpha 0.3).

5.4 Data Smoothing

```
data_smooth = data.copy()
data['Jumlah_Terjual_MA'] = data['Jumlah_Terjual'].rolling(window=3).mean()
data['Harga_Satuan_ES'] = data['Harga_Satuan'].ewm(alpha=0.3).mean()

data[['Jumlah_Terjual', 'Jumlah_Terjual_MA', 'Harga_Satuan', 'Harga_Satuan_ES']].head(8)
```

Show hidden output

- **Output:** Nilai pada data menjadi lebih halus (tidak terlalu fluktuatif) untuk melihat tren.

	Jumlah_Terjual	Jumlah_Terjual_MA	Harga_Satuan	Harga_Satuan_ES
0	25.000000	NaN	1933.000000	1933.000000
1	35.000000	NaN	257.000000	947.117647
2	36.000000	32.000000	0.025000	514.655251
4	37.911765	36.303922	231.000000	402.671338
5	25.000000	32.970588	1254.950888	710.009534
6	35.000000	32.637255	308.000000	573.325992
7	37.911765	32.637255	163.000000	439.180757
8	37.911765	36.941176	3160.000000	1305.360042